

CM n°2 : Les Bases de l'ANOVA

De la décomposition de la variance à sa visualisation et son interprétation



**Université
Grenoble Alpes**

Quentin Sénant

quentin.senant@univ-grenoble-alpes.fr

Université Grenoble Alpes

1. Le LM des t -tests :
Visualisation et
Interprétation

2. Décomposer la variance
d'un t -test

3. L'ANOVA à 1 facteur

4. Décomposition,
Visualisation et
Interprétation

5. Comparaisons à 1 ddl

6. Les Conditions
d'Applications, en
résumé



Les modèles statistiques

En statistiques inférentielles, toute observation se décompose en une partie **modélisée** et une **erreur non modélisée** que l'on appelle résidu :

$$\text{Observation} = \text{Modèle} + \text{Erreur} \quad \Longleftrightarrow \quad \text{Erreur} = \text{Observation} - \text{Modèle}$$

→ La **composante systématique** décrit la structure que le modèle cherche à expliquer : c'est la partie prévisible des données, elle est expliquée par les VI du modèle.

→ La **composante aléatoire** rassemble les diverses sources de variabilité autour de cette composante systématique. C'est par exemple la variabilité résiduelle (i.e., l'erreur) ou, lorsque les mesures sont répétées, la variabilité intra-sujets.

Le modèle linéaire du t -test indépendant

Le t -test à 2 échantillons indépendants est un modèle linéaire :

$$Y_i = \underbrace{\beta_0 + \beta_1 \times X}_{\substack{\text{composante systématique :} \\ \text{moyenne de l'échantillon} \\ + \text{effet de la VI}}} + \underbrace{e_i}_{\substack{\text{composante aléatoire :} \\ \text{variabilité résiduelle}}}, \quad \underbrace{e_i \sim \mathcal{N}(0, \sigma^2)}_{\substack{\text{nulle en moyenne et de variance constante} \\ \text{(i.e., indépendante de la VI)}}$$

β_0 est l'*intercept*, graphiquement c'est l'ordonnée à l'origine de la droite représentant l'effet statistique brut. Ici, il représente la moyenne ajustée de l'échantillon. Il a la même unité que la VD.

β_1 représente l'effet brut : c'est ce que l'on doit ajouter à β_0 pour obtenir la moyenne de la modalité d'intérêt, il s'exprime donc par rapport à β_0 . Graphiquement c'est la pente du modèle, autrement dit : $\beta_1 = \frac{\Delta VD}{\Delta VI}$. Il a donc pour unité celle de la VD par celle de la VI.

Enfin, le résidu $e_i = Y_i - \hat{Y}_i$ est l'écart entre l'observation i et la droite du modèle.

Nota : C'est de l'hypothèse $e_i \sim \mathcal{N}(0, \sigma^2)$ que découlent les conditions d'application. De plus, si l'on s'intéresse uniquement aux valeurs ajustées par le modèle sur l'échantillon et non aux inférences sur la population alors la composante systématique se notera : $\hat{Y}_i = b_0 + b_1 \times X$.

Codage des VI catégorielles

Dans un *t*-test indépendant, la VI peut être codée de plusieurs façons. Le *dummy coding* et le *sum-to-zero coding*.

→ Avec le *dummy coding*, on code en 0 une modalité de référence (groupe contrôle ou *baseline*) tandis que l'autre modalité est codée 1. Le codage par défaut de JASP et jamovi code en 0 les modalités dans l'ordre alphanumérique, puis 1 l'autre condition. L'ordonnée à l'origine, b_0 , correspond alors à la moyenne de cellule de la modalité de référence, tandis que b_1 représente la différence de moyennes inter-modalités.

→ Avec le *sum-to-zero coding*, les deux modalités sont codées de telle manière à ce que la somme de leur code soit nulle. Si l'on a que deux conditions, on choisit typiquement les valeurs de $-0,5$ et $+0,5$ pour conserver un écart inter-modalités d'une seule unité. L'origine du graphe se situe alors à mi-chemin entre eux et donc b_0 représente la tendance centrale de l'échantillon entier (ici la moyenne générale ou *grand mean*). Puisque **l'écart inter-modalité reste d'une seule unité**, la pente b_1 du modèle conserve ici la même valeur et la même interprétation.

Le codage est donc susceptible de modifier les valeurs de b_0 et de b_1 selon les situations, mais il ne modifie pas les valeurs de VD prédites par le modèle.

Représentation graphique du t -test

Paramètres libres du t -test indépendant




Figure 1: Signification des paramètres libres du t -test indépendant.

Note. Les points représentent les observations individuelles, les violons leur distribution et les segments pointillés les moyennes de chaque modalité. La ligne noire représente le modèle ajusté et la bande grise son intervalle $\pm 1,96 SE$. Ici, le recodage modifie l'ordonnée à l'origine, b_0 , mais conserve la pente puisque ΔX reste de 1, cela ne modifie pas non plus les $\hat{Y}_i$ ni les résultats du t -test. Notez que je représente des données

Formaliser H_0 et H_1

On compare le score de Rappel Indicé au RL/RI-16 entre deux groupes indépendants :

Groupe	Effectif	Moyenne	Écart-type
Contrôle	$n_C = 20$	$m_C = 12$	$s_C = 0,80$
Alzheimer	$n_A = 20$	$m_A = 8$	$s_A = 0,80$

H_0 : les deux groupes ont la même moyenne dans la population. Autrement dit, sous H_0 , la différence de moyennes attendue vaut 0 :

$$H_0 : \mu_A = \mu_C, \quad \Longleftrightarrow \quad H_0 : \mu_A - \mu_C = 0$$

H_1 : les moyennes de rappels indicés sont différentes selon la présence d'une pathologie ou non :

$$H_1 : \mu_A \neq \mu_C$$

Valeur du t -test indépendant

$t(38) = -15,81, p < .001$ indique que la différence observée à μ_0 est de 15,81 *se*. Les données soutiennent donc l'hypothèse d'un score plus faible dans le groupe Alzheimer.

Taille d'effet du t -test (à apprendre)

La significativité statistique indique la compatibilité des données avec H_0 . La **taille d'effet** décrit l'ampleur de l'écart observé. Pour un t -test à deux échantillons indépendants, le **d de Cohen exprime la différence entre les moyennes en unités d'écart-type** :

$$d = \frac{b_1}{s_{\text{combiné}}} = \frac{m_A - m_C}{s_{\text{combiné}}} = \frac{8 - 12}{0,80} = -5,00$$

où $s_{\text{combiné}}$ est l'écart-type combiné, il résume la dispersion des observations autour de la moyenne de leur propre groupe. Exprimer la taille d'effet de manière standardisée retire l'unité de la variable initiale, ce qui permet de réaliser des comparaisons inter-protocoles (e.g., de prise en charge thérapeutique) quelque soit la VD (e.g., score clinique) étudiée.

Le signe négatif indique ici que le score moyen est plus faible dans le groupe Alzheimer. Son ampleur, $|d| = 5$, indique un écart de **cinq écarts-types** entre les deux groupes.

De plus, une taille d'effet est indépendante de la taille d'échantillon et de la statistique de test. Ainsi, là où $p \xrightarrow{n \rightarrow +\infty} 0$ et $|t| \xrightarrow{n \rightarrow +\infty} +\infty$ la taille d'effet ne fait qu'osciller autour de sa vraie valeur dans la population, au même titre que la moyenne.

Standardiser la taille d'effet

Taille d'effet et statistique de test




Figure 2: De la différence brute b_1 à la taille d'effet standardisée d .

Note. Chaque déplacement du curseur tire un nouvel échantillon dans deux populations dont les moyennes valent 12 et 8 et dont l'écart-type vaut 0,80. Ainsi, $\hat{d}$ fluctue

Seuils du d de Cohen pour les SHS (à connaître)

Puisqu'une taille d'effet standardisée permet la comparaison inter-protocoles, Cohen a proposé des repères adaptés aux sciences sociales pour l'interprétation du d .

Valeur absolue du d	Interprétation
$< 0,20$	Effet négligeable
$0,20 > d < 0,50$	Effet petit
$0,50 > d < 0,80$	Effet moyen
$> 0,80$	Effet fort

NB : Ce n'est pas parce-que les seuils proposés sont inférieurs à 1 que le d de Cohen y est borné ! De telles valeurs sont très rares mais restent possibles.

Annexe : En GLM il faudra utiliser d'autres tailles d'effet ; par exemple les odds ratios en régression logistique (Bernoulli, Binomiale).

Comparaison de deux modèles emboîtés

Sous H_0 , la valeur pour β_1 est imposée/fixée à 0, on parle de modèle nul ou de modèle contraint :

$$H_0 : Y_i = \beta_0 + e_i = 30 + e_i$$

Dans le modèle nul, la pente de l'effet statistique (ici β_1) est un **paramètre fixé à 0** par l'hypothèse nulle.

Sous H_1 , l'effet statistique β_1 devient en revanche un paramètre libre ajustable auprès de l'échantillon, on parle de modèle augmenté :

$$H_1 : Y_i = \beta_0 + \beta_1 X + e_i, \quad \beta_1 = m_A - m_C$$

La question devient : **le paramètre libre permet-il de réduire suffisamment l'erreur par rapport au modèle nul ?**


Les moindres carrés ordinaires (annexe)

La technique des **moindres carrés ordinaires** (*ordinary least squares*, OLS) est une technique de maximum de vraisemblance qui permet de trouver de manière analytique (i.e., en *one-shot* pour les logiciels stats) les valeurs de b_0 et de b_1 qui minimisent l'erreur quadratique moyenne :

$$\mathcal{L}_{\text{MSE}(Y_i, \hat{Y}_i)} = \frac{1}{n} \sum_{i=1}^n \left[Y_i - \underbrace{(b_0 + b_1 X_i)}_{\text{composante systématique}} \right]^2.$$

On parle de « moindres carrés » car la méthode élève les résidus au carré avant de les additionner. De plus, on dit qu'à partir de deux paramètres, la $\mathcal{L}_{\text{MSE}}$ décrit une surface d'erreur. Les moindres carrés pondérés de Welch en sont une version pondérée de telle manière à ce que les observations associées à une variance moindre pèsent plus fortement dans l'ajustement du modèle.

Ajouter un paramètre libre réduit l'erreur



Les OLS choisissent la valeur qui minimise l'erreur




Figure 3: Ajouter un paramètre libre permet au modèle de rapprocher ses prédictions des observations.

Note. Sous H_0 , b_0 prédit les deux groupes. Sous H_1 , l'ajout de b_1 autorise une différence entre eux. Les segments représentent les résidus et les bandes les IC 95 % de la moyenne prédite.

t-tests : décomposition de la variance

La **décomposition de la variance** est à la base de l'analyse de la variance (ANOVA). L'ANOVA généralise le *t*-test ; on peut donc réexprimer le *t*-test dans ce cadre.

La variance (*MSE*) décrit l'éloignement des observations autour d'une valeur ajustée. Dans le *t*-test indépendant, la composante systématique permet de représenter la différence inter-modalités.

Une observation éloignée du modèle produit un grand résidu.

Décomposition des sommes des carrés

On code Contrôle = 0 et Alzheimer = 1. Le modèle nul prédit une moyenne commune, $H_0 : \hat{Y} = b_0 = 10$. Le modèle augmenté prédit une moyenne par groupe, $\hat{Y} = 12 - b_1 X$.

Source	Écart considéré	Somme des carrés
Systématique , intergroupes	Prédiction du modèle augmenté à la moyenne générale	$SS_{\text{modèle}} = \sum_i (\hat{Y}_i - 10)^2 = 160$
Aléatoire , intragroupe	Observation à la prédiction de son groupe	$SS_{\text{erreur}} = \sum_i (Y_i - \hat{Y}_i)^2 = 24,32$
Totale , sous H_0	Observation à la moyenne générale	$SS_{H_0} = \sum_i (Y_i - 10)^2 = 184,32$

La dispersion totale se partage entre la **part expliquée par la VI** et la **part restant dans les résidus** :

$$\underbrace{SS_{H_0}}_{184,32} = \underbrace{SS_{\text{modèle}}}_{160} + \underbrace{SS_{\text{erreur}}}_{24,32} \quad \leftrightarrow \quad \underbrace{SS_{\text{Totale}}}_{184,32} = \underbrace{SS_{\text{systématique}}}_{160} + \underbrace{SS_{\text{aléatoire}}}_{24,32}$$

Ainsi, $SS_{\text{modèle}} = SS_{H_0} - SS_{\text{erreur}}$ mesure la **réduction de l'erreur** apportée par la prise en compte de l'effet du facteur.

Décomposition exacte (à apprendre)


La variance sous le modèle nul se partage entre la composante captée par l'effet de la pathologie et donc modélisée, et celle qui reste dans les résidus :

$$SS_{H_0} = SS_{\text{modèle}} + SS_{\text{erreur}}$$

Autrement dit :

- SS_{H_0} : dispersion totale à expliquer sous le modèle nul.
- $SS_{\text{modèle}}$: dispersion retirée par l'ajout de la composante systématique et de ses paramètres libres. On parle aussi de SS_{between} ou de dispersion inter-modalité.
- SS_{erreur} : dispersion restant dans la composante aléatoire et donc dans les résidus. On parle aussi de SS_{within} ou de dispersion intra-modalité.

Décomposition de la variance par les sommes des carrés



SS_{H_0}	SS_{erreur}	$SS_{\text{modèle}}$	Décomposition
------------	----------------------	----------------------	---------------

$$SS_{H_0} = \sum e_{i,H_0}^2 = 184,32$$




Figure 4: Les sommes des carrés quantifient différents écarts au modèle.

Note. SS_{H_0} décrit la dispersion relative au modèle nul. Elle se décompose en une part systématique modélisée, $SS_{\text{modèle}}$, et une part aléatoire restant dans les résidus, SS_{erreur} .

Carrés moyens et équivalence entre t et F

Un **carré moyen** (*mean square*, MS) est une somme des carrés divisée par ses degrés de liberté résiduels correspondants, ce sont donc des variances.

Source	ddl	Carré moyen
Effet du groupe	systématique : $2 - 1 = 1$	$MS_{\text{modèle}} = 160/1 = 160$
Erreur	résiduels : $N - 2 = 38$	$MS_{\text{erreur}} = 24,32/38 = 0,64$

Le modèle nul estime b_0 . Le modèle augmenté estime b_0 et b_1 : **un seul paramètre supplémentaire** sert à tester l'effet du groupe.

$$F(1, 38) = \frac{160}{0,64} = 250 = t(38)^2.$$

Cette équivalence concerne le **test de Student bilatéral à variances égales** et l'ANOVA classique à deux groupes. Le signe de t indique le sens de la différence, tandis que $F \geq 0$.

Pourquoi un test omnibus ?

L'**ANOVA indépendante à un facteur** compare une VD quantitative entre k modalités d'un facteur catégoriel. Chaque participant appartient à une seule modalité.

Le test **omnibus** pose une question globale sur les moyennes. Tester toutes les paires séparément produit :

$$C = \frac{k(k-1)}{2} \text{ comparaisons.}$$

À titre d'illustration, pour C tests indépendants dont toutes les hypothèses nulles sont vraies ; alors la probabilité de comettre au moins un faux positif sur l'ensemble des comparaisons par paires possibles est de :

$$\Pr(\text{au moins un faux positif}) = 1 - (1 - \alpha)^C.$$

Avec $k = 4$ et $\alpha = .05$, on obtient $C = 6$ et un risque de **26,5 %**. C'est énorme !

Comparaisons multiples : FWER et FDR

A apprendre : On peut contrôler deux choses, soit le **FWER** soit le **FDR**. **FWER** (*family-wise error rate*) : probabilité de commettre **au moins un faux positif** dans une famille de tests. **FDR** (*false discovery rate*) : % de faux positifs parmi les résultats significatifs (nulle si aucun résultat significatif).

Méthode	Contrôle	Principe	Quand l'utiliser ?
Bonferroni	FWER	Seuil par test : α/C	Pour quelques comparaisons ; méthode simple mais conservatrice.
Holm	FWER	Seuils progressifs selon les p ordonnées	Choix général pour des comparaisons ciblées ; au moins aussi puissant que Bonferroni.
Tukey	FWER	Ajustement adapté aux différences de moyennes	Toutes les comparaisons par paires en ANOVA classique.
Benjamini–Hochberg	FDR	Seuils adaptés au rang des p	Nombreux tests exploratoires, avec une proportion de fausses découvertes tolérée.

Règle de pouce : Holm pour des hypothèses ciblées, Tukey pour toutes les paires, Benjamini–Hochberg pour l'exploration à grande échelle. Bonferroni et Holm acceptent des tests dépendants. Benjamini–Hochberg suppose l'indépendance.

Exemple : cognition sociale et test des Faux Pas

La **Démence Fronto-Temporale comportementale** altère la cognition sociale et l'attribution d'états mentaux à autrui (*théorie de l'esprit*, TOM). Elle apparaît vers 50-65 ans et induit de profonds changements de la personnalité. Elle peut être de diagnostic différentiel compliqué avec les profils psychiatriques bipolaires ou schizophrénique si on ne la connaît pas.

Le test des **Faux Pas** évalue la compréhension de situations sociales. Dans notre exemple, le score maximal vaut **60 points** et un score élevé indique une meilleure performance.

Modalité j	n_j	Moyenne m_j	Écart-type s_j
DFT comportementale	10	29	9
Bipolaire	10	36	8
Contrôle	10	45	8,5

Question : les scores moyens diffèrent-ils selon le groupe ? Pour cela on accomplit une **ANOVA à un facteur à 3 modalités**.

Modèles nul et complet : hypothèses omnibus

En omnibus sous H_0 , les moyennes de population sont égales :

$$H_0 : \mu_{\text{DFT}} = \mu_{\text{Bipolaire}} = \mu_{\text{Contrôle}}.$$

Le modèle nul ajuste une moyenne commune : $\hat{Y} = m_{\text{échantillon}}$. Ses résidus valent $Y - m_{\text{échantillon}}$.

Sous H_1 , au moins deux moyennes de population diffèrent.

Le modèle complet autorise une moyenne par modalité :

$$Y = \beta_0 + \beta_1 X + \beta_2 X + \varepsilon.$$

Pour $k = 3$ modalités, il estime **un intercept et $k - 1 = 2$ coefficients/pentes**. En omnibus, où l'on test tous les effets possibles conjointement, la comparaison évalue le gain apporté par ces deux paramètres à la fois par rapport à $H_0 : \mu_{\text{DFT}} = \mu_{\text{Bipolaire}} = \mu_{\text{Contrôle}}$.

Dispersion intergroupe, intragroupe et ratio F

Dans ce plan équilibré, la **moyenne générale** (*grand mean*) est la moyenne des moyennes :

$$m_{\text{échantillon}} = \frac{29 + 36 + 45}{3} = 36,67.$$

Composante	Écarts considérés	Carré moyen
Systématique , intergroupe (<i>between</i>)	Moyennes de groupes à la moyenne générale	$MS_{\text{modèle}}$
Aléatoire , intragroupe (<i>within</i>)	Observations à leur moyenne de groupe	MS_{erreur}

$$F = \frac{MS_{\text{modèle}}}{MS_{\text{erreur}}}.$$

Sous H_0 , les deux carrés moyens estiment la même variance. À effectifs et dispersion intragroupe fixés, **écarter les moyennes augmente F** .

Dispersion inter et intragroupe




Figure 5: Influence de la séparation des moyennes et de la dispersion intragroupe sur l'ANOVA.

Note. Les half-violins représentent la densité intramodale des observations empiriques. ω^2 : taille d'effet conseillée lors du test omnibus (car corrigée) en ANOVA indépendante. Sa correction par les ddl la laisse prendre des valeurs négatives ce qui signal un ou plusieurs paramètres libres d'effet négligeable.

La loi de Fisher-Snedecor (à apprendre)

F ne prend que des valeurs positives ou nulles car il s'agit d'un rapport de carrés.

Sa loi dépend de deux degrés de liberté :

$$F_{\text{observé}} \sim F(\text{ddl}_{\text{modèle}}, \text{ddl}_{\text{erreur}}) \quad \text{sous } H_0$$

Ici, ddl modèle correspond au nombre de paramètres libres de la comparaison de modèles emboîtés entre le modèle augmenté et le modèle contraint. La p -value correspond à l'aire à droite de $F_{\text{observé}}$ sous la distribution nulle.

De la table du F à la valeur critique (annexe)

Avant les logiciels, on utilisait des tables du F pour obtenir la valeur critique associée à α . Ici :

$ddl_{numérateur} = 2$, $ddl_{dénominateur} = 27$, $\alpha = .05$ Soit ici : $F_{crit}(2, 27) \approx 3,35$.

d.f.D.	$\alpha = 0.05$																		
	d.f.N.																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
1	161.4	199.5	215.7	224.6	230.2	234.0	236.8	238.9	240.5	241.9	243.9	245.9	248.0	249.1	250.1	251.1	252.2	253.3	254.3
2	18.51	19.00	19.16	19.25	19.30	19.33	19.35	19.37	19.38	19.40	19.41	19.43	19.45	19.45	19.46	19.47	19.48	19.49	19.50
3	10.13	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79	8.74	8.70	8.66	8.64	8.62	8.59	8.57	8.55	8.53
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.91	5.86	5.80	5.77	5.75	5.72	5.69	5.66	5.63
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.68	4.62	4.56	4.53	4.50	4.46	4.43	4.40	4.36
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	4.00	3.94	3.87	3.84	3.81	3.77	3.74	3.70	3.67
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64	3.57	3.51	3.44	3.41	3.38	3.34	3.30	3.27	3.23
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.35	3.28	3.22	3.15	3.12	3.08	3.04	3.01	2.97	2.93
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.14	3.07	3.01	2.94	2.90	2.86	2.83	2.79	2.75	2.71
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.98	2.91	2.85	2.77	2.74	2.70	2.66	2.62	2.58	2.54
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.90	2.85	2.79	2.72	2.65	2.61	2.57	2.53	2.49	2.45	2.40
12	4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.80	2.75	2.69	2.62	2.54	2.51	2.47	2.43	2.38	2.34	2.30
13	4.67	3.81	3.41	3.18	3.03	2.92	2.83	2.77	2.71	2.67	2.60	2.53	2.46	2.42	2.38	2.34	2.30	2.25	2.21
14	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.65	2.60	2.53	2.46	2.39	2.35	2.31	2.27	2.22	2.18	2.13
15	4.54	3.68	3.29	3.06	2.90	2.79	2.71	2.64	2.59	2.54	2.48	2.40	2.33	2.29	2.25	2.20	2.16	2.11	2.07
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.54	2.49	2.42	2.35	2.28	2.24	2.19	2.15	2.11	2.06	2.01
17	4.45	3.59	3.20	2.96	2.81	2.70	2.61	2.55	2.49	2.45	2.38	2.31	2.23	2.19	2.15	2.10	2.06	2.01	1.96
18	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.46	2.41	2.34	2.27	2.19	2.15	2.11	2.06	2.02	1.97	1.92
19	4.38	3.52	3.13	2.90	2.74	2.63	2.54	2.48	2.42	2.38	2.31	2.23	2.16	2.11	2.07	2.03	1.98	1.93	1.88
20	4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.39	2.35	2.28	2.20	2.12	2.08	2.04	1.99	1.95	1.90	1.84
21	4.32	3.47	3.07	2.84	2.68	2.57	2.49	2.42	2.37	2.32	2.25	2.18	2.10	2.05	2.01	1.96	1.92	1.87	1.81
22	4.30	3.44	3.05	2.82	2.66	2.55	2.46	2.40	2.34	2.30	2.23	2.15	2.07	2.03	1.98	1.94	1.89	1.84	1.78
23	4.28	3.42	3.03	2.80	2.64	2.53	2.44	2.37	2.32	2.27	2.20	2.13	2.05	2.01	1.96	1.91	1.86	1.81	1.76
24	4.26	3.40	3.01	2.78	2.62	2.51	2.42	2.36	2.30	2.25	2.18	2.11	2.03	1.98	1.94	1.89	1.84	1.79	1.73
25	4.24	3.39	2.99	2.76	2.60	2.49	2.40	2.34	2.28	2.24	2.16	2.09	2.01	1.96	1.92	1.87	1.82	1.77	1.71
26	4.23	3.37	2.98	2.74	2.59	2.47	2.39	2.32	2.27	2.22	2.15	2.07	1.99	1.95	1.90	1.85	1.80	1.75	1.69
27	4.21	3.35	2.96	2.73	2.57	2.46	2.37	2.31	2.25	2.20	2.13	2.06	1.97	1.93	1.88	1.84	1.79	1.73	1.67
28	4.20	3.34	2.95	2.71	2.56	2.45	2.36	2.29	2.24	2.19	2.12	2.04	1.96	1.91	1.87	1.82	1.77	1.71	1.65
29	4.18	3.33	2.93	2.70	2.55	2.43	2.35	2.28	2.22	2.18	2.10	2.03	1.94	1.90	1.85	1.81	1.75	1.70	1.64
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27	2.21	2.16	2.09	2.01	1.93	1.89	1.84	1.79	1.74	1.68	1.62
40	4.08	3.23	2.84	2.61	2.45	2.34	2.25	2.18	2.12	2.08	2.00	1.92	1.84	1.79	1.74	1.69	1.64	1.58	1.51
60	4.00	3.15	2.76	2.52	2.37	2.25	2.17	2.10	2.04	1.99	1.92	1.84	1.75	1.70	1.65	1.59	1.53	1.47	1.39
120	3.92	3.07	2.68	2.45	2.29	2.17	2.09	2.02	1.96	1.91	1.83	1.75	1.66	1.61	1.55	1.50	1.43	1.35	1.25
∞	3.84	3.00	2.60	2.37	2.21	2.10	2.01	1.94	1.88	1.83	1.75	1.67	1.57	1.52	1.46	1.39	1.32	1.22	1.00

Aire critique et p -value du F




Figure 6: Distribution de F sous H_0 , zone de rejet et position de la statistique observée.

Note. La forme de la distribution et F_{crit} dépendent des degrés de liberté. La p -value correspond à l'aire sous H_0 située à droite de $F_{\text{observé}}$.

Décomposition des sommes des carrés


L'ANOVA décompose la dispersion totale en une **composante systématique**, associée aux différences entre groupes, et une **composante aléatoire**, qui reste au sein des groupes.

Source	Dispersion mesurée	Valeur
Totale : SS_{total}	Observations autour de la moyenne générale	3 241,92
Systématique : $SS_{\text{modèle}}$	Moyennes des groupes autour de la moyenne générale , pondérées par leurs effectifs	1 286,67
Aléatoire : SS_{erreur}	Observations autour de la moyenne de leur propre groupe	1 955,25

$$\underbrace{SS_{\text{total}}}_{3\,241,92} = \underbrace{SS_{\text{modèle}}}_{1\,286,67} + \underbrace{SS_{\text{erreur}}}_{1\,955,25}.$$

À retenir : distinguer les groupes réduit l'erreur de prédiction. Cette réduction correspond à $SS_{\text{modèle}}$.

Décomposition de la variance par les sommes des carrés



SS_{total}	SS_{erreur}	$SS_{\text{modèle}}$	Décomposition
---------------------	----------------------	----------------------	---------------

$$SS_{\text{total}} = \sum e_{ij,H_0}^2 = 3241,92$$




Figure 7: Les sommes des carrés quantifient différents écarts au modèle.

Note. $SS_{\text{total}} = SS_{H_0}$ décrit la dispersion autour de la moyenne générale. Elle se décompose en une part modélisée, $SS_{\text{modèle}}$, et une part aléatoire restant dans les résidus, SS_{erreur} .

Des degrés de liberté au calcul de F

Le modèle complet estime $k = 3$ moyennes sur $N = 30$ observations. Chaque **carré moyen** vaut $MS = SS/ddl$.

Source	Somme des carrés	ddl	Carré moyen
Modèle	1 286,67	$k - 1 = 2$	$1\,286,67/2 = 643,33$
Erreur	1 955,25	$N - k = 27$	$1\,955,25/27 = 72,42$
Total	3 241,92	$N - 1 = 29$	

Les ddl se décomposent aussi : $29 = 2 + 27$. Les carrés moyens s'expriment en unités de la VD au carré.

$$F(2, 27) = \frac{MS_{\text{modèle}}}{MS_{\text{erreur}}} = \frac{643,33}{72,42} = 8,88, \quad p = .001.$$

Tailles d'effet en ANOVA: l' η^2 et l' ω^2 (à apprendre)

Après la significativité, on décrit la force de l'association statistique, donc **l'intérêt pratique**. Les deux tailles d'effet les plus courantes en ANOVA sont l' η^2 et l' ω^2 , ce sont des **proportions de réduction de l'erreur par rapport à celle commise sous H_0** .

→ L' η^2 s'utilise **uniquement** lorsque la comparaison de modèles se fait sur un seul paramètre libre. Il vaut :

$$\eta^2 = \frac{SS_{\text{modèle}}}{SS_{\text{total}}} = \frac{1286,67}{3241,92} = .397$$

→ L' ω^2 **corrige** par les ddl, porte sur la population, et s'utilise dès lors que l'on intègre plus d'un paramètre libre à la fois, donc tout le temps lors des tests omnibus. Il vaut :

$$\omega^2 = \frac{SS_{\text{modèle}} - df_{\text{modèle}} MS_{\text{erreur}}}{SS_{\text{total}} + MS_{\text{erreur}}} = \frac{1286,67 - (2 \times 72,42)}{3241,92 + 72,42} = .345$$

Conclusion : la VI Pathologie est associée au score du test des faux pas et semble responsable d'environ 35% de la variance totale dans la population ($F(2, 27) = 8,88, p < .001, \omega^2 = .345$) et $\eta^2 = 40\%$ dans l'échantillon.

Repères usuels pour l' η^2 et l' ω^2 en SHS (à connaître)

Proportion de variance expliquée	Interprétation
$< .06$	Effet faible
$.06 < \eta^2 \text{ ou } \omega^2 < .14$	Effet moyen
$.14 < \eta^2 \text{ ou } \omega^2$	Effet fort

Contrairement au d de Cohen, les valeurs d' η^2 sont des proportions et sont donc bornées entre 0 et 1. De plus, du fait de la correction appliquée à l' ω^2 celui-ci peut prendre des valeurs négatives : cela suggère alors un modèle surparamétré et des paramètres libres négligeables.

Attention : Dans tous les cas, ce seront les comparaisons de modèles ne différant que par un seul et unique paramètre libre qui informeront sur les différences inter-modalités cruciales et sur le sens de l'effet. La composante systématique doit donc nécessairement être redécomposée suite à un test omnibus...

Attention n°2 : Ces seuils sont surtout proposés lorsqu'un seul facteur est présent. Si on souhaite récupérer l'effet d'un facteur en présence d'autres VI que l'on souhaiterait contrôler alors il faut utiliser une taille d'effet "partielle" et les seuils proposés changent alors.

Table d'ANOVA : formules de calcul

Les statistiques descriptives suffisent au calcul : n_j est l'effectif, m_j la moyenne, s_j l'écart-type du groupe j et m la moyenne générale.

Source	Somme des carrés (SS)	ddl	Carré moyen (MS)
Systématique	$SS_M = \sum_j n_j (m_j - m)^2$	$k - 1$	$SS_M / (k - 1)$
Aléatoire	$SS_E = \sum_j (n_j - 1) s_j^2$	$N - k$	$SS_E / (N - k)$
Total	$SS_T = SS_M + SS_E$	$N - 1$	

$$F = \frac{MS_M}{MS_E}, \quad \omega^2 = \frac{SS_M - (k - 1)MS_E}{SS_T + MS_E}.$$

Table d'ANOVA appliquée à l'exemple

Source	Formule	Modalité	n	Moyenne	Écart-type
Systématique	$SS_M = \sum_j n_j (m_j - m_{\text{échantillon}})^2$			m_j	s_j
Aléatoire	$SS_E = \sum_j (n_j - 1) s_j^2$	DFT comp.	10	29	9
Total	$SS_T = SS_M + SS_E$	Bipolaire	10	36	8
		Contrôle	10	45	8,5

Table d'ANOVA :

Source	SC (SS)	ddl (df)	CM (MS)	F	p	ω^2
Patho	1286,67	2	643,33	8,88	.001	.345
Aléatoire	1955,25	27	72,42			
Total	3241,92	29				

Report : $F(2, 27) = 8.88$, $p = .001$, $\omega^2 = .345$. L'effet de la Pathologie explique 35% de la variance dans la population.

Du test omnibus aux contrastes à 1 ddl

L'omnibus, $F(2, 27) = 8,88$, $p = .001$, soutient l'existence d'une différence entre moyennes. Un **contraste** précise la comparaison et son sens.

Pour chaque contraste, on construit une colonne de codage X telle que $\sum_j X_j = 0$. On choisit ici son échelle pour que les ensembles de moyennes comparés soient séparés de **1 unité sur X** . Ainsi, dans le modèle $\hat{Y} = b_0 + bX$, la pente b correspond directement à la **différence de moyennes testée**.

Un contraste possède **1 seul paramètre libre**.

Codage de la VI

Avec un b_0 (ordonnée à l'origine, ou *intercept* en anglais), un facteur à k modalités nécessite $k - 1$ colonnes de codage. Pour trois modalités :

$$Y = b_0 + b_1 X_1 + b_2 X_2 + e$$

b_1 et b_2 modélisent les différences d'intérêt entre les moyennes de modalités (e.g., des contrastes orthogonaux). **C'est le codage qui détermine leur interprétation.**

R, JASP et jamovi utilisent par défaut le *dummy* et le *treatment coding* (i.e., sa généralisation à plus de 2 modalités), et c'est l'ordre alphanumérique qui détermine quelle est la modalité de référence. En sciences expérimentales on préfère un *dummy* ou *treatment coding* où c'est le groupe contrôle qui est codé en 0, d'où le terme de *treatment coding*.

Changer de codage ne change ni les valeurs ajustées, ni les résidus, ni les conclusions du test omnibus.

Treatment coding

Le *dummy* et le *treatment coding* comparent chaque modalité à une condition de référence codée 0, par défaut la première dans l'ordre alphanumérique. Il vaut mieux remplacer cette modalité de référence par celle qui fait le plus de sens pour votre interprétation : votre modalité contrôle.

Modalité	X_1 : DFT	X_2 : Bipolaire	Tendance centrale
Contrôle	0	0	b_0
DFT comp.	1	0	$b_0 + b_1$
Bipolaire	0	1	$b_0 + b_2$

Ici, la modalité **Contrôle** est la référence :

$$b_0 = 45, \quad b_1 = 29 - 45 = -16, \quad b_2 = 36 - 45 = -9$$

Deux contrastes orthogonaux pour trois groupes

Avec $k = 3$ modalités, l'effet possède **2 ddl**. On choisit deux contrastes orthogonaux :

$$C_1 = m_{\text{DFT}} - m_{\text{Bipolaire}}, \quad C_2 = \frac{m_{\text{DFT}} + m_{\text{Bipolaire}}}{2} - m_{\text{Contrôle}}.$$

On normalise les colonnes de codage pour que les deux ensembles comparés soient séparés de **1 unité sur X** :

Modalité	$X_1 : C_1$	$X_2 : C_2$
Contrôle	0	-2/3
DFT	+1/2	+1/3
Bipolaire	-1/2	+1/3

$$\Delta X_1 = \frac{1}{2} - \left(-\frac{1}{2}\right) = 1,$$

$$\Delta X_2 = \frac{1}{3} - \left(-\frac{2}{3}\right) = 1.$$

Chaque colonne somme à zéro et les deux colonnes sont **orthogonales** (produit scalaire = 0) :

$$\langle X_1, X_2 \rangle = 0 \times \left(-\frac{2}{3}\right) + \frac{1}{2} \times \frac{1}{3} - \frac{1}{2} \times \frac{1}{3} = 0.$$

À apprendre. Si les deux contrastes sont orthogonaux alors ils décomposent les **2 ddl du facteur en deux comparaisons indépendantes à 1 ddl**.

Orthogonal contrast coding

Le modèle utilise les deux colonnes orthogonales précédentes : $\hat{Y} = b_0 + b_1 X_1 + b_2 X_2$. Ici, Comme les colonnes somment à zéro, l'ordonnée à l'origine b_0 correspond à la **moyenne générale** :

$$b_0 = m_{\text{échantillon}} = \frac{45 + 29 + 36}{3} = 36,67.$$

Comme chaque contraste sépare les moyennes comparées de **1 unité sur X** , les coefficients b_1 et b_2 correspondent directement aux différences de moyennes :

$$b_1 = m_{\text{DFT}} - m_{\text{Bipolaire}} = 29 - 36 = -7,$$

$$b_2 = \frac{m_{\text{DFT}} + m_{\text{Bipolaire}}}{2} - m_{\text{Contrôle}} = \frac{29 + 36}{2} - 45 = -12,5.$$

Modalité j	$X_1 : C_1$	$X_2 : C_2$	Valeur ajustée
Contrôle	0	-2/3	$b_0 - \frac{2}{3}b_2$
DFT	+1/2	+1/3	$b_0 + \frac{1}{2}b_1 + \frac{1}{3}b_2$
Bipolaire	-1/2	+1/3	$b_0 - \frac{1}{2}b_1 + \frac{1}{3}b_2$

→ Le codage change l'interprétation des paramètres, mais **pas les valeurs ajustées, les résidus ni le test omnibus**.

Représentation graphique de l'ANOVA à un facteur

Paramètres libres de l'ANOVA à un facteur




Figure 8: Deux paramétrisations d'un même modèle d'ANOVA à un facteur.

Note. Le codage modifie l'interprétation des paramètres, mais pas les prédites ni le test omnibus. Les segments horizontaux en bas de graphique indiquent les comparaisons à 1 ddl associées aux deux codages, leur encart rapportent les tests sur b_1 et b_2 .

Contraste C_1 : DFT et Bipolaire

Le premier contraste utilise :

$$X_1 : \quad \text{Contrôle} = 0, \quad \text{DFT} = +\frac{1}{2}, \quad \text{Bipolaire} = -\frac{1}{2}.$$

Les deux moyennes comparées sont séparées de **1 unité** sur X_1 :

$$\Delta X_1 = \frac{1}{2} - \left(-\frac{1}{2}\right) = 1.$$

La pente représente donc directement leur différence :

$$b_1 = m_{\text{DFT}} - m_{\text{Bipolaire}} = 29 - 36 = -7.$$

La somme des carrés associée vaut : $SS_{C_1} = 245$, avec :

$$F_{C_1}(1, 27) = \frac{245}{72,42} = 3,38, \quad p = .077.$$

Contraste C_2 : Pathologies et Contrôle

Le second contraste utilise :

$$X_2 : \quad \text{Contrôle} = -\frac{2}{3}, \quad \text{DFT} = +\frac{1}{3}, \quad \text{Bipolaire} = +\frac{1}{3}.$$

La moyenne des deux groupes pathologiques et le groupe contrôle sont séparés de **1 unité** sur X_2 :

$$\Delta X_2 = \frac{1}{3} - \left(-\frac{2}{3}\right) = 1.$$

La pente représente donc directement :

$$b_2 = \frac{m_{\text{DFT}} + m_{\text{Bipolaire}}}{2} - m_{\text{Contrôle}} = \frac{29 + 36}{2} - 45 = -12,5.$$

La somme des carrés associée vaut $SS_{C_2} = 1041.67$, avec :

$$F_{C_2}(1, 27) = \frac{1041,67}{72,42} = 14,38, \quad p < .001.$$

Reconstituer la composante systématique

Modèle : $\hat{Y} = b_0 + b_1 \times X_1 + b_2 \times X_2$

SC : $SS_{\text{modèle}} = SS_{C_1} + SS_{C_2} = 245 + 1041,67 = 1286,67$

Source	Estimateur	SC	ddl	CM	F	p	Taille d'effet
Pathologie		1286,67	2	643,33	8,88	.001	$\omega^2 = .345$
$\hookrightarrow C_1$: DFT vs Bipolaire	$b_1 = -7,00$	245,00	1	245,00	3,38	.077	$\eta^2 = .076$
$\hookrightarrow C_2$: Pathos vs Contrôle	$b_2 = -12,50$	1041,67	1	1041,67	14,38	< .001	$\eta^2 = .321$
Erreur		1955,25	27	72,42			
Total		3241,92	29				

Conditions d'application des LM (à apprendre)

Les hypothèses portent sur la composante aléatoire du modèle. En découlent les conditions d'application suivantes :

- **Normalité** : les résidus suivent approximativement une loi $\mathcal{N}$ dans chaque modalité. Autrement dit les violons de chaque modalité doivent avoir une forme de **cloche symétrique** autour de la moyenne ($\approx C_{50}$) de la modalité et **non aplatie**. Enfin, les queues de la distribution ne doivent pas non plus être trop épaisses.
- **Homoscédasticité** : la dispersion des résidus est comparable entre les modalités, elle ne doit pas dépendre de la ou des VI. Si l'on peut dessiner un entonnoir reliant le violon d'une modalité à une autre alors elle est bafouée. Cela **arrive souvent avec les VD bornées** (décomptes, proportions et variables binaires, temps de réaction, etc.).
- **Indépendance** : un résidu ne doit pas permettre de prédire systématiquement les autres. **Les résidus sont inter-dépendants en cas de mesures répétées si on applique le mauvais modèle (il faut traiter les différences intra-individuelles ici).**
- **En ANOVA à mesures répétées, on ajoute l'hypothèse de sphéricité**, abordée plus tard.
- **S'il existe au moins une VI quantitative (modèles d'ANCOVA et de régression), on ajoute l'hypothèse de linéarité dans les paramètres/dans la forme fonctionnelle**, abordée elle aussi plus tard.

Nota : Ces hypothèses concernent les modèles à composante aléatoire gaussienne et demandent avant tout à ce que le modèle *fit* bien les données. À d'autres composantes aléatoires, d'autres conditions d'application.

Normalité des résidus (à apprendre)

On pose $e_i \sim \mathcal{N}(0, \sigma^2)$.

Le **test de Shapiro-Wilk** est souvent utilisé pour tester cette condition d'application. Seulement, il ne constitue pas une preuve de normalité : un petit échantillon peut manquer de puissance, tandis qu'un grand échantillon peut rendre significatifs des écarts minimes.

Enfin, on pourra aussi se servir des indices du *skewness* et du *kurtosis* servant respectivement à estimer l'asymétrie et l'aplatissement de la distribution. Le *skewness* doit tendre vers 0 (≤ 2) tandis que le *kurtosis* ne doit pas être excessif (≤ 7 , idéalement proche de 3) si l'effectif est suffisamment grand, **mais l'évaluation graphique doit toujours rester prioritaire.**

A apprendre : Pour l'évaluation graphique de la normalité on peut utiliser un **Q-Q plot** et la forme de la distribution des résidus (leur densité via les violons !).

Un plan équilibré rend l'ANOVA relativement robuste à des écarts modérés, surtout lorsque les effectifs sont suffisants.

Evaluation graphique de la normalité des résidus




Figure 9: Distribution des résidus, Q-Q plots et test de Shapiro-Wilk selon l'effectif.

Note. La médiane (C_{50} , en orange), doit être à peu près la moyenne des résidus (donc 0) si on pose l'hypothèse d'une loi $\mathcal{N}$. $\gamma_1 = \text{skewness}$; $\kappa = \text{kurtosis}$ de Pearson ($\kappa = 3$ sous normalité). Les lois Binomiale ($\mathcal{B}$), Gamma (Γ) et de Poisson ($\mathcal{P}$) illustrent respectivement des VD binaires/proportions, des temps de réaction et des décomptes. Shapiro-Wilk peut faire des faux positifs et faux négatifs.

Homoscédasticité (à apprendre)

L'homoscédasticité suppose une dispersion comparable entre les modalités :

$$\sigma_1^2 \approx \sigma_2^2 \approx \dots \approx \sigma_k^2$$

Le test de Levene peut être utilisé, mais l'examen graphique reste, là encore, prioritaire.

A apprendre. Une forte hétéroscédasticité peut être traitée avec une méthode adaptée, notamment l'**ANOVA de Welch**, qui pondère les groupes selon la précision de leur moyenne et ajuste les ddl. Elle est à choisir par défaut en présence d'hétéroscédasticité.

Les moindres carrés pondérés (WLS) constituent une alternative à Welch qui se généralise à l'ANCOVA et la régression. Elle est proposée par JASP et jamovi.

Homoscédasticité et effet « entonnoir »




Figure 10: Comparaison de la dispersion conditionnelle entre les modalités pour différentes formes de distribution.

Note. Les pointillés orange représentent $m_j \pm 2s_j$: leur largeur reste constante sous homoscédasticité et augmente dans l'effet « entonnoir ». Le test de Levene évalue $H_0 : \sigma_A^2 = \sigma_B^2 = \sigma_C^2$.

Indépendance des résidus (à apprendre)

L'indépendance dépend d'abord du **plan expérimental**.

Dans une ANOVA indépendante, chaque participant contribue à une seule modalité. Les observations de participants différents ne doivent pas s'influencer systématiquement (i.e., pas de répétition de la mesure de VD en intra-sujet, pas d'analyse de paires de participants comme des couples, jumeaux, pas de mesures longitudinales, etc.).

Une dépendance ignorée fausse l'estimation de la composante aléatoire et donc de l'incertitude. Lorsque plusieurs observations proviennent d'un même *cluster* de mesures répétées, il faut utiliser un modèle qui représente cette **structure d'effets aléatoires**, par exemple une **ANOVA à mesures répétées** ou un modèle mixte (aussi appelé hiérarchique ou multiniveaux).

Références utiles

→ Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences* (2nd ed.). Routledge.

→ Olejnik, S., & Algina, J. (2003). Generalized eta and omega squared statistics: Measures of effect size for some common research designs. *Psychological Methods*, 8(4), 434–447.