

CM n°1 : Introduction

Variables, inférence sur une mesure et sur la population



**Université
Grenoble Alpes**

Quentin Sénant

quentin.senant@univ-grenoble-alpes.fr

Université Grenoble Alpes

1. Variables

2. Quelques statistiques
descriptives

3. La démarche
inférentielle

4. Du z -score au t -test

5. Tests d'hypothèse
nulle, p -value, α , β et
IC



Variables indépendantes et dépendantes

Les **variables indépendantes** (VI) sont celles dont on pose l'hypothèse qu'elles ont un effet sur la **variable dépendante** (VD). La valeur de la VD est donc censée changer selon la valeur ou modalité prise par la VI.

Les VI peuvent être **manipulées** au cours d'une expérience ou **invoquées** et prennent alors leur valeur indépendamment de l'expérimentateur.

Les modalités d'une VI catégorielle peuvent être **indépendantes** (e.g., intersujets) ou **appariées** (e.g., intrasujets) en cas de mesures répétées.

Graphiquement, la **VD se place sur l'axe des ordonnées (y)**, donc l'axe vertical. Lorsqu'il n'y a qu'une seule **VI**, elle se place sur l'axe des abscisses (x), donc l'axe horizontal.

Exemple d'étude intrasujet

On souhaite connaître l'effet d'une prise en charge de type TCC relativement à une thérapie de psychologie positive sur la symptomatologie dépressive, évaluée par l'inventaire de dépression de Beck (BDI, allant de 0 à 63).

Pour des raisons éthiques, tous les patients suivent les deux thérapies dans un ordre contrebalancé (i.e., la moitié des sujets commence par la TCC puis reçoit ensuite une prise en charge par psy. positive, l'inverse pour l'autre moitié des sujets). Les mesures sont donc répétées sur les participants : la VI Thérapie est donc **manipulée** et **appariée** car les mesures sont répétées en intrasujet.

La VI est manipulée par l'expérimentateur-clinicien. La VD est le **score de dépression**.

Représentation graphique intrasujet




Figure 1: Scores de dépression selon la thérapie. (Données bidon !)

Note. Violons : densité des distributions, calculés via une *kernel density estimation*. Lignes rouges (spaghettis) : effets intrasujets entre les mesures appariées d'un même participant. Ligne noire : effet intrasujet moyen reliant la moyenne des deux modalités entourée de son IC95% ($\pm 1.96 \text{ se}$).

Exemple n°2

NHANES (*National Health and Nutrition Examination Survey*) est une enquête américaine qui associe entretiens et examens de santé standardisés. J'utilise ici les mesures de pression artérielle d'adultes de 20 à 39 ans issus des données NHANES 2009–2012.

On souhaite déterminer si la **pression artérielle systolique moyenne** diffère selon le sexe.

La VI Sexe comporte deux modalités : femme et homme. C'est une VI **invoquée**.

La VD est la **pression artérielle systolique moyenne**, exprimée en mmHg.

Représentation graphique intersujet




Figure 2: Pression artérielle systolique moyenne selon le sexe chez des adultes de 20 à 39 ans. Données NHANES 2009–2012.

Note. Les violons représentent la densité des distributions. L'effet intersujets moyen est représenté par une ligne noire reliant la moyenne des deux modalités entourée de son IC95% (approx. $\pm 1.96 \text{ se}$). Chaque participant appartient à une seule modalité de la VI.

Variables et $N < O < I < R$

Les variables se distinguent aussi selon la structure de la mesure. Cette distinction aide à choisir les tests inférentiels et à comprendre la logique des tests non paramétriques.


Niveau	Définition	Exemple
Nominal	Modalités nommables, sans ordre	Sexe biologique
Ordinal	Modalités ordonnables	Échelle de Likert, réponses graduées
Intervalle	Écarts interprétables, sans zéro naturel	Différence de temps de réaction
Rapport	Écarts interprétables et zéro naturel	Temps de réaction, âge, taille, décomptes, proportions

Pourquoi $N < O < I < R$?

En allant de **N** vers **R**, chaque niveau suivant conserve les opérations autorisées par le niveau précédent.

- **Nominal** : dénombrer les observations dans chaque modalité.
- **Ordinal** : dénombrer et comparer les rangs.
- **Intervalle** : dénombrer, comparer, additionner et soustraire.
- **Rapport** : dénombrer, comparer, additionner, soustraire, multiplier et diviser.

L'arbre des tests paramétriques et non paramétriques



Les tests non paramétriques (annexe)

Les tests non paramétriques exploitent la règle **N < O < I < R** : plusieurs d'entre eux utilisent seulement l'**ordre des observations plutôt que leurs valeurs brutes**. Ils conviennent donc aux VD ordinales et aux **distributions continues non normales** (e.g., les décomptes).

Plan	Test paramétrique	Alternative non paramétrique
2 groupes indépendants	<i>t</i> de Student indépendant	Mann-Whitney-Wilcoxon
2 mesures appariées	<i>t</i> de Student apparié	Wilcoxon signed-rank
> 2 groupes indépendants	ANOVA intersujets	Kruskal-Wallis
> 2 mesures répétées	ANOVA intrasujets	Friedman

Tests fondés sur les rangs et Welch tests (annexe)

→ **Tests fondés sur les rangs** : le test statistique est construit directement à partir des rangs des observations ou des différences.

- **Mann-Whitney-Wilcoxon** : classe ensemble les observations de deux groupes indépendants.
- **Wilcoxon signed-rank** : classe les différences absolues entre deux mesures appariées, puis tient compte de leur signe.
- **Kruskal-Wallis** : classe ensemble les observations de plusieurs groupes indépendants.
- **Friedman** : classe les conditions à l'intérieur de chaque sujet dans un plan à mesures répétées.

Ces tests sont à utiliser en cas de violation de la condition d'application de normalité.

→ **Méthodes paramétriques pour hétéroscédasticité** : elles conservent les valeurs quantitatives originales mais modifient leur pondération lors de l'ajustement des paramètres du modèle. Le **Welch t -test** et l'**ANOVA de Welch** autorisent des variances différentes entre groupes. Ces tests se basent sur les **moindres carrés pondérés (WLS)** qui donnent davantage de poids aux observations estimées avec la meilleure précision. Ces méthodes restent paramétriques parce-qu'elles ne transforment pas les données en rangs.

Ces tests et les WLS sont à utiliser en cas de violation de la condition d'application de variance homogène = constante = "d'homoscédasticité" des résidus.

Principe de fidélité d'un test psychologique

En psychologie, nous sommes amenés à utiliser beaucoup de variables différentes, que ce soit pour caractériser un patient au travers d'un questionnaire avant une thérapie, pour aider au diagnostic d'une démence, etc. Du fait de la quantité de questionnaires proposés, certains sont évidemment meilleurs que d'autres et l'on peut attendre d'un bon test ou d'un bon questionnaire qu'il soit fiable et valide.

La **fiabilité** (fidélité, ou *reliability*) décrit la reproductibilité ou la précision d'un score. **En situation de test-retest elle augmente lorsque les différences de score mesuré sur un même individu sont faibles.** On souhaite donc que les différences mesurées représentent plus des variations dans le fonctionnement individuel que celles d'un mauvais test.

Mesures de la fidélité d'un test psychologique

La fidélité dépend du résultat que l'on souhaite reproduire :

Résultat étudié	Indice adapté
Cohérence des items d'un questionnaire	α de Cronbach ou ω de McDonald
Stabilité d'un score continu	ICC (<i>intra-class correlation coefficient</i> ; test-retest ou inter-évaluateur)
Stabilité d'une catégorie	κ de Cohen

L' α de Cronbach suppose que les items contribuent à peu près de manière égale au construit que souhaite mesurer le test psychologique. Or, puisqu'il y a souvent de nombreux items à un même questionnaire, on peut s'attendre, encore une fois, à ce que certains soient meilleurs que d'autres pour représenter le construit psychologique que l'on veut mesurer. L' ω de McDonald est donc préférable dès lors que l'on dispose d'un modèle factoriel qui décrit les dimensions du questionnaire (e.g., extraversion, agréabilité, stabilité émotionnelle, etc. au Big-5) : ici les items peuvent contribuer différemment à la mesure du construit (ici la personnalité).

Selon Senja Stirn, dans tous les cas, **un coefficient d'environ .90 est souvent considéré comme le minimum souhaitable en clinique**. Le Big-5 respecte ce prérequis, d'autres questionnaires comme le MBTI, descendent à ~ 0.6 pour certaines dimensions.

Ces coefficients sont accessibles sous JASP par défaut, pour jamovi il faudra installer seolmatrix pour l'ICC, et meddecide pour le κ .

Principes de validités d'un test psychologique

La validité peut, elle, concerner plusieurs aspects...

La **validité diagnostique** pose la question de savoir si un test distingue correctement les cas pathologiques des cas non pathologiques. Elle est mesurée à l'aide de différents indices : la sensibilité, la spécificité, l'AUC d'une ROC, etc. Tous ces indices sont compris entre 0 et 100% et doivent idéalement tendre vers 100%. Pour construire la courbe ROC d'un test diagnostique on utilise des modèles comme la régression logistique.

La **validité de construit** concerne l'adéquation entre le score obtenu et le construit que l'on souhaite réellement mesurer. Une mesure peut être très reproductible tout en mesurant autre chose que le construit visé. Pour l'évaluer, on peut notamment examiner la **structure factorielle du test** : on vérifie si les items se regroupent selon un nombre limité de dimensions cohérentes et interprétables, conformément au modèle théorique. C'est par exemple le cas du modèle des Big Five, qui distingue cinq grandes dimensions de la personnalité.

La **validité prédictive** d'un test psychologique pose la question de savoir si le test prédit effectivement un comportement ou un résultat futur (e.g., un patient obtenant un score élevé à l'échelle de dépression de Beck présente-t-il un risque plus important de passage à l'acte ?). Pour l'évaluer, on examine l'association entre le score au test et la survenue ultérieure du comportement considéré.

La **validité convergente** peut aussi être examinée : on cherche alors à vérifier que les résultats du questionnaire **sont corrélés** à d'autres mesures de construits identiques ou proches.

Quelques statistiques descriptives

Les indices descriptifs portent sur **l'échantillon** de l'étude. Ils se répartissent en deux familles :

- **indices de position** ou de **tendance centrale** : mode, médiane et moyenne ;
- **indices de dispersion** ou **d'erreur** : fréquence hors mode, *mean absolute error* (*mean absolute deviation* ; notée MAE ou MAD) et écart-type (i.e., *root mean squared error*).

Médiane et MAE (annexe)

La **médiane** partage les données en deux parts égales : 50 % des observations se trouvent de chaque côté. Elle peut être utilisée dès les variables ordinales et est très **robuste aux observations extrêmes**.



La **MAE** est la moyenne des écarts absolus à un centre a :

$$\mathcal{L}_{\text{MAE}(a)} = \frac{1}{n} \sum_{i=1}^n |y_i - a|$$

La médiane est précisément le centre a qui minimise cette fonction de perte. Sous le capot des logiciels stats, la médiane est estimée à partir de la *loss function* de la MAE par méthode du **maximum de vraisemblance** (*maximum likelihood*) : on parle de définition *m-estimateur* de la médiane.

Nota : **Estimer les paramètres d'un modèle** consiste à choisir les valeurs qui rendent ses prédictions aussi proches que possible des observations, selon une **fonction de perte** (une erreur de modélisation). Pour certains modèles simples, comme l'ANOVA, ces valeurs peuvent être obtenues directement par une **solution analytique**, c'est-à-dire calculés en *one-shot* à l'aide d'une formule. Pour des modèles plus complexes, on utilise souvent une **optimisation numérique** : un algorithme appelé optimiseur modifie progressivement les paramètres afin de réduire la perte.

La médiane est le minimum de la perte MAE



Centre envisagé = 6,75

Figure 3: MAE en fonction du centre envisagé.

Note. Le demi-violon représente la densité des observations. Le curseur permet de faire varier le centre envisagé ; les segments rouges représentent alors les erreurs absolues entre ce centre et chaque observation. Le point bleu indique la MAE correspondante dans le *subplot* droit. La médiane minimise cette fonction de perte.

Moyenne, MSE et RMSE (à apprendre)

La **moyenne** est la somme des observations divisée par leur nombre. Elle est très sensible aux observations extrêmes.



La **MSE** (*mean squared error*) est la moyenne des écarts au carré (erreurs quadratiques) à un centre a :

$$\mathcal{L}_{\text{MSE}(a)} = \frac{1}{n} \sum_{i=1}^n (y_i - a)^2$$

Notez que cette **formule de la MSE est celle d'une variance** ! On a uniquement changé la terminologie ici.

La moyenne minimise la MSE et donc également sa racine carrée, la **RMSE qui revient, elle, à un écart-type**. La moyenne, parce-qu'elle minimise la MSE et la RMSE est également un *m-estimateur*.

La moyenne minimise les pertes MSE et RMSE



Centre envisagé = 7,42

Figure 4: MSE et RMSE en fonction du centre envisagé.

Note. La barre orange du *subplot* gauche représente le centre envisagé. Le curseur permet de le faire varier. Les segments rouges représentent les erreurs entre ce centre et chaque observation. La moyenne minimise la MSE. Comme la racine carrée est strictement croissante, elle minimise également la RMSE.

La démarche inférentielle NHST

L'inférence consiste à interpréter une observation faite sur un **échantillon** comme révélatrice d'une caractéristique sous-jacente de sa **population parente**. Plusieurs approches existent et posent chacune une question différente.

En fréquentisme (il y en a de plusieurs types : Fisher, Neyman-Pearson, NHST (*null hypothesis significance testing*) ou tests *interval-null*). On évalue une conclusion par des réplifications hypothétiques de l'étude. On formule des hypothèses, on choisit une statistique de test, puis on mesure la compatibilité des données avec H_0 . Les décisions reposent sur des seuils contrôlant les erreurs de conclusion à long terme lors des réplifications (*p-value* : combien de % de ma distribution de référence pour H_0 est au moins aussi extrême que ce que j'observe ?).

La démarche inférentielle fréquentiste pose une hypothèse nulle H_0 ("il n'y a pas d'effet dans la population") et une hypothèse alternative H_1 ("il existe un effet statistique dans la population"). On évalue ensuite la compatibilité de l'observation avec H_0 via un seuil alpha qui détermine la statistique critique du test. Il contrôle le risque de déclarer un effet comme étant significatif à tort dans la population, c'est le risque d'erreur de type I (de commettre un faux positif). On utilise la *p-value* pour rejeter H_0 si elle est inférieure à α .

Composante systématique et aléatoire (annexe)

Une VD observée dépend à la fois de ce que le modèle explique et d'une variabilité qui subsiste entre les observations. Un modèle statistique distingue donc deux composantes. La **composante systématique** décrit comment les prédicteurs X_i (les VI) font varier la valeur attendue de la VD. La **composante aléatoire** décrit comment les observations Y_i (la VD) peuvent varier autour de cette valeur attendue, même pour des observations ayant les mêmes valeurs de X_i .

Pour chaque observation i , on définit sa **moyenne conditionnelle** $\mu_i = \mathbb{E}(Y_i \mid X_i)$. Elle correspond à la valeur moyenne attendue de Y parmi des observations possédant les mêmes valeurs des prédicteurs X_i . Dans un modèle linéaire généralisé, la composante systématique s'écrit sous forme d'un **prédicteur linéaire (i.e., d'une somme pondérée)** appelé η : $\eta_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots$ et une fonction de lien relie cette composante systématique à la moyenne conditionnelle $g(\mu_i) = \eta_i$.

Pour les modèles linéaires où l'on ne précise pas le terme "généralisé", cette fonction de lien $g()$ revient à une simple multiplication par 1 (fonction identité).

L'écriture d'un modèle, en général (annexe)

Dans tous les cas, qu'il s'agisse d'un modèle linéaire gaussien (z -score, t -test, ANOVA, ANOCVA, régression linéaire) ou d'un GLM utilisant une autre distribution, la **composante aléatoire** correspond à la distribution supposée des valeurs possibles de Y_i conditionnellement à X_i , ce que l'on note $Y_i | X_i \sim \text{Distribution}(\mu_i, \dots)$. Cette distribution/composante aléatoire peut être normale, binomiale (dont la Bernoulli), Poisson, Gamma, Inverse-Gaussienne, etc. Elle décrit la variabilité qui subsiste **autour de ce que le modèle prédit**.

$$\underbrace{g(\mu_i) = \eta_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots}_{\substack{\text{composante systématique} \\ \text{ce que les prédicteurs/VI expliquent}}} \quad \text{avec} \quad \underbrace{Y_i | X_i \sim \mathcal{D}(\mu_i, \dots)}_{\substack{\text{composante aléatoire} \\ \text{variabilité conditionnelle de la VD}}}, \quad \mu_i = \mathbb{E}(Y_i | X_i).$$

où $g()$ est la fonction de lien (fonction identité dans les modèles linéaires), où η_i est le prédicteur linéaire (donc une somme pondérée), où $Y_i | X_i$ est la distribution conditionnelle de la VD pour les valeurs de VI X_i , et où $\mathcal{D}$ est la distribution conditionnelle supposée par le modèle stat. Enfin, $\mu_i = \mathbb{E}(Y_i | X_i)$ est la moyenne conditionnelle, c'est-à-dire la valeur moyenne de la VD attendue pour ces valeurs de VI.

Quand utiliser quelle loi ?

Nature de la VD	Loi paramétrique potentiellement adaptée	Exemples en psy/neuropsych
Continue, approximativement symétrique autour de la moyenne	Normale	QI et autres scores standardisés sur un grand échantillon normatif
Décompte entier, ≥ 0 , sans borne supérieure fixe	Poisson	Nombre d'erreurs au <i>Wisconsin Card Sorting Test</i> ; score brut ou intrusions aux fluences verbales
Nombre de succès sur un nombre fixé d'essais	Binomiale	Rappel libre ou rappel différé sur 16 items au RL/RI-16 : score compris entre 0 et 16
Réponse binaire	Bernoulli	Item rappelé / non rappelé ; réponse correcte (1) / incorrecte (0)
Continue, strictement positive et asymétrique à droite	Gamma < Inverse-Gaussienne < Tweedie	Temps de réaction, temps de réalisation d'une tâche

→ Le choix de la loi dépend d'abord du **support de la VD** : continue ou discrète, bornée ou non (peut-elle montrer un effet de plancher ou de plafond ?)

→ D'un point de vue hétéroscédasticité, les temps de réaction sont souvent des variables embêtantes : leur variance tend à augmenter selon une loi de puissance de la moyenne : autrement dit, les conditions où les réponses sont plus lentes sont souvent aussi celles où elles sont (beaucoup) plus dispersées.

Fonctions de lien (annexe)

La **fonction de lien** $g()$ relie la moyenne conditionnelle μ_i au prédicteur linéaire η_i :

$$g(\mu_i) = \eta_i = \beta_0 + \beta_1 X_{1i} + \dots$$

Elle permet au modèle de respecter le **support de la VD**. Quelques exemples de fonction de lien usuelles :

Identité : $\mu \in]-\infty, +\infty[\rightarrow$ loi normale (la VD ne montre ni effet de plancher ni effet de plafond).

Log : $\mu > 0 \rightarrow$ Poisson, Gamma, Inverse-Gaussienne (variables ayant un 0 naturel ou susceptibles de montrer un effet de plancher mais pas plafond).

Logit : $0 < \mu < 1 \rightarrow$ Bernoulli / Binomiale (proportions : variables ayant un min et un max, susceptibles de montrer un effet de plancher et de plafond).

Illustration de GLMs

Normale


Poisson

Binomiale


Gamma

Inverse-Gaussienne

Moyenne et dispersion conditionnelles



Distribution de Y | X sélectionné



Prédicteur : X = 0.00



L'écriture d'un modèle, en particulier (à apprendre)

Cette année et sans doute pour le reste de votre cursus, ce sera principalement le cas particulier du **modèle linéaire gaussien** qui sera développé : il est nécessaire de le maîtriser avant de pouvoir passer au reste.

Ici, la fonction de lien $g()$ est l'identité, i.e., $g(\mu_i) = \mu_i$, et on peut donc l'oublier.

La composante aléatoire (la distribution des données autour du modèle) suit une loi normale :

$$Y_i | X_i \sim \mathcal{N}(\mu_i, \sigma^2), \quad \mu_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots$$

Ici, le modèle se note comme une somme pondérée à laquelle on ajoute une petite erreur de modélisation sur laquelle on pose l'hypothèse qu'elle suit une loi normale :

$$Y_i = \underbrace{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots}_{\substack{\text{composante systématique} \\ \mu_i = \mathbb{E}(Y_i | X_i)}} + \underbrace{\varepsilon_i}_{\substack{\text{composante aléatoire} \\ \varepsilon_i \sim \mathcal{N}(0, \sigma^2)}} .$$

Les t -tests, ANOVA, ANCOVA et régressions linéaires, et corrélation de Pearson utilisent cette écriture : ce sont des sommes pondérées.

De l'observation au résidu : un passage par le modèle

Une fois le modèle estimé, on obtient une moyenne conditionnelle prédite, bref une prédiction moyenne sur la VD qui est fonction de nos VI : $\hat{\mu}_i = \mathbb{E}(\widehat{Y_i} \mid X_i)$.

L'observation empirique y_i est la valeur effectivement mesurée. Le **résidu mesure l'écart entre cette observation et ce que le modèle attend/prédit** : $e_i = y_i - \hat{\mu}_i$. Par exemple, le z -score est un résidu standardisé (i.e., divisé par l'écart-type).

Le résidu permet ainsi de vérifier si les écarts observés au modèle sont compatibles avec la **distribution conditionnelle supposée**.

Dans un modèle linéaire gaussien (e.g., t -test, ANOVA, ANCOVA), on s'intéresse à la normalité (les observations doivent former une courbe en cloche autour du modèle) et à la variance des résidus qui doit être constante tout du long du modèle.

Modèle linéaire et résidus, GLM et résidus quantiles






Figure 6: De la distribution conditionnelle de la VD aux résidus dans un t -test, une ANOVA, une ANCOVA (et leurs généralisations). *Note.* À gauche, le modèle représente la moyenne conditionnelle $\hat{\mu}_i = \mathbb{E}(\widehat{Y_i} | X_i)$. À droite, en mode VD, plusieurs distributions $Y | X$ illustrent la variabilité conditionnelle autour de cette prédiction. Pour l'ANCOVA, les distributions des trois groupes sont représentées à 45 ans. Pour les GLM il faudra choisir les résidus quantiles pour vérifier les conditions d'application. Les GLM sont accessibles sous JASP par défaut.

Exemple du TMT

Lors d'un stage de M2 neuropsychologie clinique, vous participez à l'aide au diagnostic d'une population adulte. Un patient se présente à la consultation mémoire, accompagné de son épouse. Elle rapporte des changements de personnalité et des troubles qui semblent atteindre les fonctions exécutives.

Le bilan comprend le **Trail Making Test** (TMT). Ses deux parties évaluent respectivement la vitesse de traitement de l'information et la flexibilité mentale.

Le Trail Making Test



Les temps de réaction sont bornés gauche

Dans la partie A, le patient relie les chiffres dans l'ordre numérique. Dans la partie B, il alterne chiffres et lettres.

Dans les deux cas, on mesure un **temps de réaction**. Cette variable possède un zéro naturel et est donc une variable de type rapport.

À cause de cette borne gauche, on dit que les observations tendent à s'écrabouiller (elles sont *squashed*) contre la borne. De plus, elles forment une longue queue à droite.

Ce faisant, les temps de réaction suivent rarement une loi normale mais plutôt une loi Gamma (ou inverse-gaussienne, ou Tweedie).




Figure 7: Distribution typique des temps de réaction, simulés ici par une loi Γ (Gamma).

Normes percentiles du TMT

Puisque la distribution des temps de réaction s'éloigne très fortement d'une loi normale, en clinique on utilise des normes percentiles pour situer un patient dans une population de référence.

Un percentile indique la proportion de la population de référence qui obtient une valeur $\leq$ à une valeur donnée, ce qui fournit un rang pour chaque observation. Par exemple, le C_{25} correspond à une valeur atteinte ou dépassée par 75 % de cette population. Exemple des normes GREFEX pour le TMT :

Centile	C_5	C_{10}	C_{25}	C_{50}	C_{75}	C_{90}	C_{95}
Partie A (s)	66	53	43	31	27	23	20
Partie B (s)	125	110	84	69	55	47	43
B - A (s)	81	66	49	30	22	15	12

On souhaite effectuer un test unilatéral à 5% de risques de faux positifs, pour cela on utilise la statistique critique du C_5 . Un temps de 50 s en partie A se situe entre C_{25} et C_{10} (non significatif). Un temps de 140 s en partie B se situe **au-delà de C_5** ($p < 5\%$ i.e., $p < .05 \rightarrow$ significatif). Un écart **B - A de 90 s se situe également au-delà de C_5** et suggère un trouble **significatif** de flexibilité mentale.

En clinique, les seuils du C_5 , $C_{2.5}$ sont les plus utilisés, leur équivalent en loi z est respectivement de -1.645 et de -1.96 . Ces seuils correspondent à un seuil α de risque de faux positif (erreur de type I).

Situer un patient dans une distribution




Figure 8: Percentile d'une observation individuelle selon une distribution normative fictive de temps de réaction.

Note. La barre représente le temps de réaction du patient, que le curseur permet de faire varier. Son rang percentile correspond au %age de la population présentant un $TR \leq$ au sien, soit l'aire sous la courbe (AUC) à gauche de la barre, multipliée par 100. Au 95ème percentile, le patient répond donc plus lentement que 95 % de cette population. Les hachures délimitent les 5 % de temps de réaction les plus longs, au-delà du 95ème percentile.

La Loi des Grands Nombres (LGN)

Suivons un échantillon auquel on ajoute progressivement des observations.

Chaque nouvelle observation modifie sa moyenne. Lorsque la taille N de l'échantillon augmente, les grandes fluctuations de l'estimation de μ deviennent cependant de plus en plus rares : l'estimation est d'autant plus stable et précise que N est grand. La moyenne observée tend alors à se stabiliser autour de la moyenne de la population μ .

Le Théorème Central Limite (TCL)

Imaginons maintenant de nombreux échantillons indépendants, tous de même taille. Leurs moyennes forment une **distribution d'échantillonnage** (i.e., l'ensemble des valeurs que prendrais leur moyenne m respective si l'on répétait la même expérience sur la même population une infinité de fois).

Lorsque la taille des échantillons augmente, cette distribution d'échantillonnage devient de plus en plus symétrique et se rapproche d'une loi $\mathcal{N}$, **même si les observations individuelles suivent une loi non normale, bornée ou asymétrique** ! Elle reste centrée sur la moyenne μ de la population et se resserre à mesure que notre précision sur l'estimation de μ augmente (i.e., à mesure que l'erreur standard se de l'estimation diminue).

Diminution de l'effet des bornes sous LGN et TCL

Avec une variable de type rapport, les observations et leurs moyennes m restent toujours supérieures ou égales au **zéro naturel**. Agréger des observations en calculant leur moyenne **ne supprimera donc jamais cette borne**.

En revanche, la moyenne de la distribution d'échantillonnage reste au même endroit tandis que notre précision sur l'estimation de la moyenne de population μ augmente.

Si l'on mesure la distance entre la borne zéro et la moyenne estimée en unités d'erreur standard se , alors la borne zéro s'éloigne progressivement de la moyenne.

Résultat : La distribution devient moins asymétrique et la masse négative produite par l'approximation normale devient négligeable.

Illustration de la LGN et du TCL




Figure 9: Effet de la taille d'échantillon sur la moyenne cumulée et sur sa distribution d'échantillonnage.

Note. La distribution des observations reste asymétrique et bornée à zéro. À gauche, la moyenne cumulée se stabilise autour de μ lorsque N augmente (LGN). À droite, la distribution d'échantillonnage décrit les moyennes obtenues sur des échantillons de même taille N . Elle se resserre autour de μ et se rapproche de l'approximation normale orange (TCL). La zone rouge représente les moyennes négatives impossibles auxquelles cette approximation attribue une probabilité, qui devient négligeable lorsque N augmente.

Les petits échantillons

Par contraintes de temps de passation, de difficultés de recrutement ou encore en raison de contraintes financières, il est rarement possible d'observer la totalité d'une population parente. L'inférence statistique repose donc nécessairement sur les données recueillies dans un **échantillon**.

Let's deal with it!

La correction de Bessel

Dans son livre *Fundamenta Astronomiae* (1818), Friedrich Bessel cherche à tirer des conclusions générales sur le mouvement des astres à partir d'observations portant sur pas moins de 3 222 étoiles ! Pour ne pas calculer à la main des équations énormes il décide alors de travailler à l'aide de multiples sous-échantillons.

Seulement, il remarque alors que les sous-échantillons sous-estiment systématiquement la variance de son méta-échantillon lorsqu'ils utilisent leur propre moyenne. On dit que ces estimations sont **biaisées** car leur moyenne diffère de la vraie valeur que l'on aurait obtenue en calculant d'emblée sur l'ensemble du méta-échantillon.

→ La variance est un estimateur biaisé car la moyenne des variances des sous-échantillon ne correspond pas (et est inférieure) à la variance du méta-échantillon. Il nous faut donc corriger la variance estimée sur l'échantillon pour estimer celle de la population.

Bessel propose alors une correction simple, mais efficace, qui reste aujourd'hui encore au cœur même des statistiques inférentielles.

Nota : Le principe de cette correction se généralise de l'échantillon à la population, et du calcul d'une variance à celui d'une MSE.

Un ddl (param. libre) est utilisé pour estimer la moyenne

L'écart-type non-corrigé s et sa version corrigée $\hat{\sigma}$ s'écrivent respectivement :

$$s = \sqrt{\frac{\sum_{i=1}^n (y_i - m)^2}{n}} \qquad \hat{\sigma} = \sqrt{\frac{\sum_{i=1}^n (y_i - m)^2}{n - 1}} \quad \nearrow$$

Note. Les flèches rappellent ici simplement que si le dénominateur diminue alors la fraction totale augmente. Ceci relève l'estimation des valeurs d'écart-type et de variance pour la population. y_i : une observation indépendante du participant i , m la moyenne, n le nombre total d'observation, $\hat{\sigma}$ l'écart-type corrigé = estimation ($\hat{}$) de l'écart-type populationnel.

La moyenne m est un **paramètre libre** : autrement dit, on cherche aussi à estimer sa valeur dans la population et plusieurs valeurs sont possibles pour celle-ci. On dit que ce paramètre libre nous **consomme un degré de liberté résiduel** : **ddl résiduel** = n **observations** - p **paramètres libres**.

Le principe généralisé de la correction de Bessel consiste à soustraire ce paramètre libre aux observations indépendantes dont on dispose : cela nous donne notre nombre de ddl résiduels. Si l'on a qu'un seul paramètre libre (e.g., la moyenne dans un *z*-score ou un *one-sample t*-test) alors on a $n - 1$ ddl résiduels.

La correction de Bessel augmente l'estimation de la variance, surtout lorsque n est petit. Son effet diminue à mesure que l'échantillon grandit. Mais en pratique, cela suffit généralement à relever l'estimation effectuée pour la variance vers sa valeur populationnelle.

Illustration des ddl (à apprendre)




Figure 10: Construction progressive d'un modèle, du one-sample t -test à l'ANOVA factorielle 2×2 .

Note. Les 40 observations forment quatre cellules expérimentales de 10 participants. Les segments rouges représentent les résidus et les courts tirets noirs les moyennes de cellule. Avec n observations et p paramètres libres, le modèle possède $n - p$ degrés de liberté résiduels. À partir de 3 paramètres libres : bleu = avec contrainte de temps de réponse, orange = sans contrainte. Notez que l'interaction est une différence de différences.

L'appariement apporte de l'information au modèle

Dans un plan indépendant, chaque participant fournit une seule observation. Dans un plan apparié, il est observé dans plusieurs conditions. Ainsi, 20 participants mesurés deux fois produisent 40 observations, mais seulement **ces observations ne proviennent que de 20 unités indépendantes**.

Les mesures d'un même participant partagent ses caractéristiques individuelles. L'appariement indique donc au modèle quelles observations proviennent d'une même personne et évoluent ensemble.

Traiter ces scores comme indépendants revient à **effacer les paires** et à considérer, à tort, que les 40 observations proviennent de 40 personnes différentes. Le modèle ne respecte alors plus le plan expérimental.

L'analyse repose donc sur les **20 changements individuels (i.e., les différences entre mesures répétées intra-participant)**. Après estimation du changement moyen, il reste **19 degrés de liberté résiduels**. Ceux-ci dépendent du nombre d'informations pouvant varier indépendamment, et non pas juste du nombre d'observations. Ce nombre d'observations indépendantes ne peut vraiment se déterminer qu'à l'aide de la connaissance du plan expérimental.

→ Malgré la perte en termes de nombre d'observations indépendantes, tenir compte de l'appariement en calculant un score de différences entre mesures répétées permet de faire en sorte que chaque participant devienne son propre contrôle !

Notion de covariance entre mesures répétées

La **covariance** désigne la tendance de deux mesures à varier ensemble.

Elle est **positive** lorsque les participants ayant un score élevé dans une condition tendent aussi à avoir un score élevé dans l'autre ; proche de **zéro** lorsqu'aucune relation systématique n'apparaît ; et est **négative** lorsque les observations tendent à évoluer en sens inverse.

Nota : Le terme de covariance renvoie plus spécifiquement au numérateur d'une corrélation, ce terme n'est pas réservé qu'aux mesures appariées, mais on le rencontrera souvent lorsque l'on traite celles-ci.

L'appariement ajoute de l'information aux données




Figure 11: Trois appariements possibles des mêmes observations.

Note. Seuls les spaghettis intrasujets, et donc la covariance des mesures répétées changent. L'analyse du *t*-test apparié repose sur les 20 différences intra-individuelles entre conditions : après estimation de la **différence moyenne**, il reste donc $20 - 1 = 19$ ddl résiduels.

Histogramme, densité et probabilité

Dans un histogramme, chaque barre représente une partie des observations. Pour construire un histogramme, on divise simplement l'effectif de chaque barre par l'effectif total (on divise la colonne du tableur par sa somme) : on obtient une **proportion**, ce faisant, la somme des proportions de toutes les barres vaut **1**.

Une courbe de densité (e.g., un violon) généralise l'histogramme, c'en est une version lissée, continue.

Avec une courbe de densité, toute l'aire sous la courbe vaut **1**. La **probabilité** d'observer une valeur dans un intervalle correspond à l'**aire sous la courbe** (*area under curve* ou AUC) dans cet intervalle.

Nota. La hauteur d'une courbe de densité ne constitue pas une probabilité. Seule une aire représente une probabilité.

Le z-score

Le z-score **standardise** (i.e., divise par l'écart-type) la distance entre une observation individuelle x_i et une moyenne m d'échantillon ou μ_0 de population. De ce fait, il perd l'unité de la VD et s'exprime dorénavant **en nombre d'écarts-types** :

$$z = \frac{x_i - \mu_0}{\sigma} \quad \text{ou} \quad z = \frac{x_i - m}{s},$$

où μ_0 et σ sont respectivement la moyenne et l'écart-type de la population, tandis que m et s sont la moyenne et l'écart-type de l'échantillon.

Diviser par l'écart-type permet donc de **standardiser la manière avec laquelle on s'exprime** : quelque soit la mesure initiale on peut se rapporter à des seuils communs pour les interpréter ; et à la valeur de $\pm 1.96\sigma$ pour effectuer un test bilatéral à $\alpha = 5\% = .05$.

Les valeurs critiques du z-score

Le z-score situe une observation dans la loi normale centrée-réduite




Figure 12: Aire sous la loi normale centrée-réduite selon la valeur de z et la direction du test.

Note. L'aire rouge représente, sous H_0 , la probabilité d'observer un z au moins aussi extrême que celui sélectionné dans la ou les directions définies par le test : sa surface est la p -value. L'aire bleue représente son complément, soit $1 - p$. Les valeurs de -1.645 ; -1.96 et -2.33 correspondent respectivement 5ème, 2.5ème et 1er percentile de la loi z .

Les notes standards (z , QI, T, etc.)

En psychologie, on appelle note standard une statistique étalonnée à partir d'une loi normale centrée-réduite (i.e., d'une loi z). Une loi normale centrée-réduite a une moyenne de 0 et un écart-type de 1 : $\mathcal{N}(\mu = 0, \sigma = 1)$. Autrement dit elle est centrée sur la moyenne (puisqu'on la soustrait aux y_i) et réduite/standardisée de telle manière à avoir un écart-type de 1 (puisqu'on a divisé les $y_i - m$ par l'écart-type σ).

À partir du z -score, on peut obtenir d'autres échelles en le multipliant par l'écart-type souhaité, puis en ajoutant la moyenne souhaitée. On parle de **transformation linéaire** car chaque score est multiplié par une constante puis décalé d'une même valeur (**somme pondérée**).

Par exemple, une note T (e.g., échelles type Weschler: WAIS, WMS, CVLT) utilise spécifiquement une moyenne de 50 et un écart-type de 10 :

$$T = 50 + 10z$$

Ces scores expriment donc la même position relative, mais sur des échelles différentes. Le QI est un exemple de note standard.

L'échelle de Stanford-Binet (annexe)

L'échelle de Stanford-Binet est, elle, étalonnée sur $\mu = 100$ et $\sigma = 15$ via $QI = 100 + 15z$.

<i>z</i> -score	Note T	QI	Rang percentile	Position
-3	20	55	$< C_1$	3 σ sous la moyenne
-2	30	70	$\approx C_2$	2 σ sous la moyenne
-1	40	85	$\approx C_{16}$	1 σ sous la moyenne
0	50	100	C_{50} : médiane	Moyenne μ_0
+1	60	115	$\approx C_{85}$	1 σ au-dessus de la moyenne
+2	70	130	$\approx C_{98}$	2 σ au-dessus de la moyenne
+3	80	145	$> C_{99}$	3 σ au-dessus de la moyenne

Nota : Le rang percentile correspond à la proportion (c'est un pourcentage) de la population obtenant un score inférieur ou égal à la valeur considérée, il peut être utilisé comme statistique critique du test.

95 % de la population a un QI compris entre 70 et 130

Un QI Stanford–Binet se situe dans une distribution de moyenne 100 et d'écart-type 15




Figure 13: Aire sous la loi normale des QI Stanford–Binet selon le score observé et la direction du test.

Note. L'aire rouge représente, sous H_0 , la probabilité d'observer un QI au moins aussi extrême que celui sélectionné dans la ou les directions définies par le test : sa surface est la p -value. L'aire bleue représente son complément, soit $1 - p$.

L'erreur standard et le t -test

L'**erreur standard** (SE ou se) mesure la **précision de l'estimation de la moyenne de population**, on divise l'écart-type d'échantillon s par la racine carré du nombre d'observations indépendantes n :

$$SE = \frac{s}{\sqrt{n}}$$

L'erreur standard SE diminue à mesure que la précision sur l'estimation sur la moyenne de population μ augmente. Pour augmenter cette précision (diminuer SE) soit l'écart-type doit diminuer, soit la taille d'échantillon doit augmenter. La SE est utilisée pour la construction d'intervalles de confiance (e.g., en utilisant IC95%: $\pm 1.96se$ ce qui correspond à 2 tests unilatéraux à 2.5%).

Le t -test standardise une différence de moyenne **par l'erreur standard de cette différence**. Par exemple, lors d'un *one-sample* t -test, on compare la moyenne observée m à une valeur de référence μ_0 , fixée sous l'hypothèse nulle $H_0 : \mu = \mu_0$.

$$t = \frac{m - \mu_0}{s/\sqrt{n}}$$

où s désigne l'écart-type estimé dans l'échantillon et n son effectif. Sous H_0 et les conditions du test, cette statistique suit une loi de Student à $n - 1$ degrés de liberté. La valeur t exprime l'écart entre la moyenne observée et la valeur de référence **en unités d'erreur standard**.

Trois types de t -tests, une même logique

On distingue trois types de t -tests:

Type de t -test	Question posée	Différence testée	Erreur standard	Paramètres libres
À un échantillon	La moyenne diffère-t-elle d'une valeur de référence μ_0 ?	$m - \mu_0$	$\frac{s}{\sqrt{n}}$	1
À échantillons appariés	La moyenne change-t-elle entre deux modalités appariées ?	$\bar{d}$, avec $d_i = x_{i2} - x_{i1}$	$\frac{s_d}{\sqrt{n}}$	1
À échantillons indépendants	Les moyennes de deux groupes distincts diffèrent-elles ?	$m_1 - m_2$	$\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$	2

La valeur $|t|$ augmente lorsque la différence observée devient grande relativement à son incertitude. **Le choix du test dépend du plan d'étude** : une référence, deux mesures liées ou deux groupes indépendants.

Nota. Le t -test apparié est un *one-sample t-test* sur les différences entre les 2 modalités de mesures répétées.

L'hypothèse *point-sharp* null (à apprendre)

Un test d'hypothèse nulle (ici bilatéral) examine une hypothèse H_0 selon laquelle **aucun effet n'existe dans la population**. Sous H_0 , les variations observées proviennent des fluctuations d'échantillonnage et de l'erreur de mesure.

H_0 peut porter sur une moyenne comparée à une valeur théorique ou sur une différence de moyennes. L'hypothèse H_1 correspond généralement à une inégalité.

Exemple : On souhaite comparer les scores de mémoire épisodique évalués par le test du RL/RI-16 items d'un groupe Alzheimer et d'un groupe contrôle. Pour cela, on effectue un t -test à deux échantillons indépendants posant les hypothèses suivantes :

$$H_0 : \mu_{Alzheimer} = \mu_{Contrôle} \qquad H_1 : \mu_{Alzheimer} \neq \mu_{Contrôle}$$

L'hypothèse *point-sharp null* (à apprendre)

Une hypothèse nulle ponctuelle (*point-sharp null*) pose qu'une différence (un effet statistique) est **strictement** égale à zéro.

Avec une grande puissance statistique, une différence infime peut devenir significative. **En pratique, une taille d'échantillon finie ne permet jamais de démontrer une égalité parfaite à toute décimale.**

Or, la p -value teste ce type d'hypothèse. On peut ici soit **rejeter** H_0 soit conclure que les données apportent **trop peu d'évidence pour la rejeter**. Toutefois, on ne peut pas ici accepter l'hypothèse nulle à l'aide de la seule p -value.

Le report statistique devra donc toujours compléter la significativité statistique par une **taille d'effet** permettant d'évaluer la significativité **pratique** de l'effet ! Mieux : on peut aussi modifier l'hypothèse étudiée et choisir $H_0 : \mu_{Alzheimer} \approx \mu_{Contrôle}$, c'est ce que font les hypothèses *interval-null*.

Hypothèse *interval null* (annexe)

Une hypothèse nulle par intervalle (*interval null*) pose qu'une différence est assez petite pour ne présenter **aucune importance en pratique**.

Elle s'appuie sur un intervalle de confiance et une taille d'effet minimale d'intérêt pratique, définie en amont.

Lorsque l'intervalle de confiance se situe entièrement dans la zone d'équivalence, il devient possible de conclure en faveur de l'équivalence pratique à un effet nul.

La p -value

La p -value est la probabilité, **sous** H_0 , d'observer une statistique au moins aussi extrême que celle calculée dans l'échantillon (pas juste la probabilité du résultat obtenu) dans le sens de l'hypothèse H_1 alternative.

Elle peut être **unilatérale** lorsque l'hypothèse est orientée ou bien **bilatérale** lorsque les deux directions d'effet sont considérées.

Les tests unilatéraux sont toutefois assez peu utilisés dans la littérature car ils sont parfois considérés comme moins conservateurs (ils feraient trop de faux positifs, erreurs de type I). Ils sont plus utilisés en clinique quand on cherche de la sensibilité aux observations pathologiques (e.g., hypothèses de maladies insidieuses). De plus, une p -value bilatérale convient aussi très bien aux hypothèses orientées, d'où le fait qu'elle constitue souvent un choix par défaut.

p -value unilatérale et bilatérale

p -value unilatérale et bilatérale




Figure 14: Seuil alpha, p -value et décision statistique.

Note. Rouge : aire critique définie par α . Orange : aire correspondant à la p -value de la statistique observée. Le résultat est significatif lorsque $p \leq \alpha$.

Intervalle de confiance (annexe)

Un intervalle de confiance à 95 % provient d'une procédure qui, répétée sur de nombreux échantillons, produit des intervalles **contenant le paramètre populationnel dans 95 % des cas**.

Sa largeur dépend de la variance des données, de la taille de l'échantillon et du taux d'erreur de type I (α , risques de faux positifs) choisi.

Les deux bornes correspondent aux seuils de deux t -tests unilatéraux. Cette idée conduit directement aux procédures TOST (*two one-sided t -tests*) utilisées pour tester une hypothèse d'équivalence à la valeur nulle.

Tester l'équivalence à l'aide du TOST (annexe)

Le TOST définit en amont deux bornes d'équivalence $-\Delta$ et $+\Delta$: chacune des bornes représente un seuil en termes de taille de l'effet statistique en-dessous duquel on peut dire que l'effet statistique que l'on a observé dans l'échantillon est nul en pratique (i.e., approximativement nul). L'équivalence à H_0 est établie lorsque l'intervalle de confiance se trouve entièrement entre ces bornes.

Trois inférences sont possibles en TOST (annexe)




Figure 15: Influence de la taille d'échantillon et des bornes d'équivalence sur une procédure TOST.

Note. L'effet standardisé observé est fixé à 0,25. Les contrôles permettent de modifier l'effectif total et les deux bornes de la taille d'effet minimale d'intérêt pratique. Pour un TOST avec $\alpha = .05$, l'équivalence est établie lorsque l'IC à 90 % est entièrement inclus dans l'intervalle d'équivalence.

Écart-type, *se* et IC (annexe)

Ces trois quantités ont la même unité que la VD, mais ne décrivent pas la même chose : *s* décrit la dispersion des observations empiriques ; *se* décrit la précision de la moyenne *m* d'échantillon pour estimer la moyenne μ de la population et l'IC exprime cette précision sous la forme d'un intervalle.

Quantité	Mesure	Formule	Question posée	Comportement si $N \rightarrow +\infty$
<i>s</i> Écart-type	Dispersion des observations individuelles autour de <i>m</i>	$s = \sqrt{\frac{\sum_{i=1}^N (y_i - \bar{y})^2}{N - 1}}$	Les participants différent-ils beaucoup les uns des autres ?	Ne diminue pas nécessairement
<i>se</i> Erreur standard	Dispersion attendue des moyennes m d'échantillon autour de la moyenne μ de population	$se = \frac{s}{\sqrt{n}}$	Avec quelle précision la moyenne est-elle estimée ?	Divisée par 2 quand <i>N</i> est multiplié par 4
IC à $1-\alpha\%$	Valeurs de μ compatibles avec l'estimation <i>m</i> et son incertitude <i>se</i>	$95\%CI \approx m \pm 1.96 \times se$ si <i>N</i> suffisamment grand et <i>m</i> pas trop proche d'une borne	Quelles valeurs de μ restent plausibles ?	Se resserre quand <i>se</i> diminue

α , β , taille d'effet et puissance (à apprendre)

- Le risque α est la probabilité d'une **erreur de type I** : déclarer un effet alors qu'il n'existe pas dans la population (on fait un faux positif).
- Le risque β est la probabilité d'une **erreur de type II** : manquer un effet qui existe dans la population (on fait un faux négatif).
- La **taille d'effet** décrit l'ampleur de l'effet et sa pertinence pratique. Elle peut être brute ou standardisée.
- La **puissance statistique** est la probabilité de détecter un effet qui existe : $\text{Puissance} = 1 - \beta$. Elle dépend d' α , de la taille d'effet, de la variabilité et de la taille de l'échantillon.

Le principe d'une analyse de puissance *a priori*, comme elle est effectuée dans le cadre fréquentiste de Neyman-Pearson consiste à chercher la taille d'échantillon N pour un effet ayant une taille d'effet d (présupposée à partir de la littérature ou d'un pré-test), et à chercher la valeur de N nécessaire pour tester l'effet avec tel taux d'erreur de type I et de type II souhaités.